



**MINISTÉRIO DA EDUCAÇÃO
SECRETARIA DE EDUCAÇÃO PROFISSIONAL E TECNOLÓGICA
INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO SUL DE MINAS GERAIS
CIÊNCIA DA COMPUTAÇÃO**

Projeto de Trabalho de Conclusão de Curso

Simulador Tático para Avaliação de Inteligência Artificial: equilíbrio entre qualidade estratégica e custo computacional na tomada de decisão de agentes autônomos

Ciências Exatas e da Terra, Ciência da Computação e Metodologia e Técnicas da Computação

2026

Muzambinho – MG

INFORMAÇÕES GERAIS

Título do projeto: Simulador Tático para Avaliação de Inteligência Artificial: equilíbrio entre qualidade estratégica e custo computacional na tomada de decisão de agentes autônomos

Orientador - Nome: Ricardo Martins

E-mail: ricardo.martins@muz.ifsuldeminas.edu.br

Endereço no Lattes: <https://lattes.cnpq.br/6440153479104482>

Discente - Nome: Gabriel Madeira

E-mail: gabrielmadeira1504@gmail.com

Endereço no Lattes: <http://lattes.cnpq.br/9023419600551197>

Membros do projeto:

Nome	Titulação máxima	Instituição Pertencente	Função	E-mail
Gabriel Madeira	Graduando em Ciência da Computação	IFSULDEMINAS - Campus Muzambinho	Autor	gabrielmadeira1504@gmail.com
Ricardo Martins	Mestre	IFSULDEMINAS - Campus Muzambinho	Orientador	ricardo.martins@muz.ifsuldeminas.edu.br
Diego Penha	Bacharel	IFSULDEMINAS - Campus Muzambinho	Coorientador	diego.penha95@gmail.com

Fonte: elaborado pelo autor (2026).

Local de Execução: IFSULDEMINAS – Campus Muzambinho.

Período de Execução: Início: Fevereiro/2026 — Término: Dezembro/2026

1. ANTECEDENTES, CARACTERIZAÇÃO DO PROBLEMA E JUSTIFICATIVA

A tomada de decisão é um dos problemas centrais da Inteligência Artificial. Segundo Russell e Norvig (2010), um agente inteligente é aquele que seleciona, a cada instante, a ação que maximiza sua medida de desempenho no ambiente em que atua. Em ambientes táticos — caracterizados por adversários, terreno com obstáculos, informação imperfeita e recursos limitados — essa seleção envolve equilibrar objetivos conflitantes: agredir e proteger-se, avançar e manter posição, decidir rápido e decidir bem.

Jogos digitais consolidaram-se como plataforma privilegiada para o estudo desses problemas. Técnicas de IA desenvolvidas para jogos servem de base para sistemas reais de decisão (MILLINGTON; FUNGE, 2016), e ambientes simulados permitem testes controlados, repetíveis e de baixo custo para a avaliação de agentes (PÉREZ-LIÉBANA et al., 2019). Abordagens como a Utility AI, que avalia ações candidatas por funções de utilidade multicritério, são amplamente empregadas na indústria (MARK; DILL, 2010).

Entretanto, a literatura e a prática de avaliação de agentes concentram-se, em geral, no resultado final das partidas: um agente é considerado melhor que outro se vence mais. Pouco se mede sobre como vence — se usa o terreno a seu favor, se troca dano de forma eficiente, se decide em tempo hábil e, sobretudo, quanto processamento consome para cada decisão. Essa avaliação baseada apenas em métricas finais limita a análise do comportamento estratégico, pois não captura posicionamento, uso de cobertura, eficiência das ações nem o custo de produzir as decisões.

Disso decorre a questão central deste trabalho: *como avaliar de forma eficaz a qualidade estratégica de agentes de IA em ambientes táticos controlados, considerando simultaneamente o valor das decisões e o custo computacional de produzi-las?*

A hipótese investigada é a de que a utilização de métricas compostas, aliada a um modelo de decisão que considera simultaneamente valor estratégico e custo computacional, permite uma avaliação mais precisa do comportamento dos agentes e produz decisões mais eficientes do que abordagens que otimizam apenas o valor estratégico. Em síntese: busca-se verificar se é possível, com uma fórmula explícita de compromisso, chegar a um modelo de decisão mais eficiente.

O trabalho justifica-se em duas frentes. Do ponto de vista científico, contribui com uma metodologia de avaliação que enxerga além da vitória, incorporando dimensões de qualidade decisória e de custo — lacuna apontada na literatura de avaliação de agentes (PÉREZ-LIÉBANA et al., 2019). Do ponto de vista prático, decisões computacionalmente

baratas e estrategicamente boas interessam a qualquer sistema embarcado ou de tempo real: jogos comerciais com orçamento de CPU por quadro, robótica móvel e sistemas autônomos em geral. A opção por medir o custo por contagem de operações, e não por tempo de relógio, torna os resultados independentes do hardware utilizado e diretamente comparáveis entre pesquisadores.

2. REFERENCIAL TEÓRICO

2.1. Agentes inteligentes e ambientes

Russell e Norvig (2010) definem agente como qualquer entidade capaz de perceber seu ambiente por meio de sensores e de agir sobre ele por meio de atuadores; um agente racional escolhe ações que maximizam sua medida de desempenho esperada. O ambiente construído neste trabalho classifica-se, na taxonomia dos autores, como parcialmente observável (o agente enxerga apenas o interior do seu cone de visão), multiagente competitivo, determinístico nas transições, sequencial e discreto. A observabilidade parcial é decisiva para o realismo do experimento: agentes oniscientes convergem para comportamentos degenerados que não transferem para problemas reais.

2.2. Inteligência artificial para jogos

Millington e Funge (2016) sistematizam o arsenal clássico da IA para jogos: máquinas de estados, árvores de comportamento (MARCOTTE; HAMILTON, 2017), sistemas de utilidade, pathfinding e táticas de posicionamento. Os autores destacam que a IA de jogos opera sob restrições severas de orçamento computacional — tipicamente uma fração de milissegundo por agente por quadro — o que torna o custo de cada decisão um critério de projeto de primeira ordem.

2.3. Utility AI e decisão multicritério

A abordagem de Utility AI (MARK; DILL, 2010) avalia cada ação candidata por uma função de utilidade que combina múltiplos fatores normalizados e ponderados, arbitrando entre objetivos conflitantes de forma contínua e ajustável. A IA heurística deste trabalho é uma instância direta dessa técnica: cada posição alcançável recebe um valor estratégico multicritério, e a de maior valor é escolhida.

2.4. Avaliação de agentes em ambientes simulados

Pérez-Liévana et al. (2019) consolidaram, com o framework GVGA, a prática de avaliar agentes de IA em baterias padronizadas com condições idênticas para todos os competidores. Três princípios dessa tradição são incorporados integralmente a este trabalho: bancos fixos de cenários (aqui, sementes de geração procedural), separação estrita entre conjunto de calibração e conjunto de teste, e métricas agregadas sobre grandes quantidades de partidas.

2.5. Custo computacional e o espectro de sofisticação

No extremo sofisticado do espectro de decisão está o Monte Carlo Tree Search (MCTS), que estima o valor de ações explorando árvores de futuros possíveis (BROWNE et al., 2012), alcançando alta qualidade estratégica ao custo de milhares de simulações por decisão. O MCTS é adotado aqui como referência teórica de teto de qualidade, e não como modelo implementado. O modelo híbrido proposto ataca exatamente o eixo que o MCTS ilustra — quanto vale cada unidade adicional de processamento — formalizando o compromisso com um parâmetro explícito de troca, em linha com a discussão de trade-offs de Browne et al. (2012).

3. OBJETIVOS

3.1. Objetivo Geral

Desenvolver um simulador tático bidimensional para avaliação sistemática de estratégias de IA em ambiente controlado, e propor um modelo híbrido de tomada de decisão que equilibre qualidade estratégica e custo computacional, medido de forma independente de hardware por contagem de operações.

3.2. Objetivos Específicos

- Construir um ambiente de simulação em grade com mecânicas de combate, cobertura direcional, percepção limitada e geração procedural de mapas por sementes;
- Implementar quatro modelos de tomada de decisão com níveis crescentes de sofisticação — aleatório, reativo, heurístico e híbrido — sob um contrato de software comum que garanta comparação justa;
- Coletar métricas de desempenho estratégico e de custo computacional em larga escala, com documentação completa e reproduzível de cada execução;

- Analisar comparativamente os modelos e verificar se o modelo híbrido proposto supera os demais em eficiência estratégica global.

4. METODOLOGIA E ESTRATÉGIA DE AÇÃO

Optou-se por desenvolver um jogo novo, construído especificamente para a pesquisa, em vez de instrumentar um jogo existente — decisão que garante controle total sobre regras, determinismo e instrumentação de medição. O gênero é o combate tático por turnos em grade, no formato todos-contra-todos com três agentes autônomos. O simulador foi implementado no motor Godot 4.7 e executa em modo visual (inspeção e demonstração) e em modo headless (lotes experimentais sem renderização). A metodologia organiza-se nas subseções seguintes: o ambiente (4.1), os agentes e sua percepção (4.2), as regras de combate (4.3), a medição de custo (4.4), o aprendizado entre partidas (4.5), os modelos comparados (4.6), as métricas (4.7), o protocolo experimental (4.8) e a infraestrutura (4.9).

4.1. Ambiente: grade, geração procedural e setores

O mapa é uma grade bidimensional de 40x40 células de quatro tipos: vazia, parede (bloqueia movimento e visão), cobertura leve e cobertura pesada (transponíveis, não bloqueiam visão, reduzem dano). A dimensão 40x40 foi validada empiricamente: com alcance de visão 8 e movimento de 3 células por turno, produz partidas com duração média observada entre 30 e 90 turnos conforme os modelos — longas o bastante para manobra e curtas o bastante para caber no limite de 100 turnos e viabilizar lotes de 1000 partidas em minutos.

Cada mapa é gerado proceduralmente a partir de uma semente inteira que alimenta um gerador congruente determinístico: a mesma semente produz sempre o mesmo mapa, os mesmos pontos de nascimento e, dadas as mesmas IAs, exatamente a mesma partida. O gerador posiciona segmentos de parede e blocos de cobertura respeitando uma zona de segurança ao redor dos nascimentos, e valida por busca em largura que todos os agentes podem se alcançar. Para impedir vantagem de terreno, o mapa é dividido em quatro setores de 20x20 e cada um dos três agentes nasce em um setor distinto, sorteado pela semente.

4.2. Agentes e percepção

Cada agente possui posição, pontos de vida (100), alcance de visão (8 células, distância de Chebyshev), orientação, estado vivo/morto e identificador de cor (verde, vermelho ou azul). São três agentes independentes — não há equipes — e o controle é estritamente um por vez, em turnos sequenciais.

A percepção é deliberadamente limitada: um agente conhece a posição de um inimigo apenas se ele estiver dentro do seu cone de visão de 120 graus, centrado na orientação, a até 8 células, com linha de visão desobstruída — paredes bloqueiam a visão; coberturas, não. A orientação acompanha a última ação: mover vira o agente para a direção do deslocamento; atacar, para o alvo. Completam o modelo perceptivo a memória tática (o agente guarda a última posição em que viu cada inimigo e investiga a mais próxima, esquecendo-a ao chegar lá e nada encontrar) e a revelação por dano (receber um tiro revela a posição do atirador mesmo fora do cone).

Integra ainda a percepção um sensor de proximidade, inspirado no detector de movimento do jogo Alien Isolation: fora do campo de visão, o agente capta um indício grosseiro do inimigo mais próximo situado a até quinze células — a direção aproximada, discretizada em oito octantes, e a faixa de distância, classificada em próximo, médio ou distante. O sensor não revela a posição exata nem é bloqueado por paredes, representando ruído e não visão. Trata-se de mecânica do ambiente, disponível igualmente a todos os modelos, de modo que a equidade da comparação se preserva; cada consulta é contabilizada no custo computacional. Sua introdução tornou as partidas mais decisivas e menos custosas para todos os modelos, ao substituir a exploração aleatória por busca orientada. Fora do alcance do sensor, o agente explora destinos sorteados por gerador semeado pela semente da partida, preservando o determinismo.

4.3. Regras de combate

O sistema é de turnos sequenciais: a cada turno completo, cada agente vivo age exatamente uma vez, um após o outro, em ordem fixa dentro da partida. Não há simultaneidade a resolver — quando um agente decide, o estado que observa já incorpora as ações dos que agiram antes no turno — nem disputa por alvo: os agentes são adversários independentes e cada um decide em seu próprio momento. Para anular o viés de agir primeiro, a ordem inicial é rotacionada entre as partidas do lote: a partida i inicia pelo agente $i \bmod 3$, de modo que cada agente inicia exatamente um terço das simulações.

No seu turno, o agente pode mover-se até 3 células (caminho validado por busca em largura em 4 direções, respeitando paredes) e executar uma ação: atacar ou permanecer. O ataque exige alvo dentro do alcance (igual ao de visão), linha de visão desobstruída e alinhamento em linha reta — horizontal, vertical ou diagonal perfeita. A restrição de linha reta é necessária para que a cobertura direcional seja efetiva; sem ela, ângulos arbitrários contornariam qualquer defesa. A cobertura é direcional e automática: um defensor está

protegido quando existe célula de cobertura ortogonalmente adjacente a ele na direção do atacante. O dano é determinístico:

$$\text{Dano} = 30 - \text{Redução}, \quad \text{Redução} \in \{0, 10, 20\}$$

com redução 10 para cobertura leve e 20 para pesada. Não há qualquer sorteio em combate: toda a aleatoriedade do experimento está confinada à geração dos mapas. A partida termina quando resta um único agente vivo (vencedor) ou ao atingir o limite de 100 turnos, caso em que é declarado empate. O valor 100 foi definido empiricamente como teto de segurança: as durações médias observadas ficam entre 30 e 90 turnos, de modo que o limite raramente interrompe partidas que convergiriam, mas impede laços infinitos de perseguição.

4.4. Custo computacional abstrato

O custo computacional de uma decisão é medido por contagem de operações elementares, e não por tempo de relógio. Três contadores são mantidos por agente: cálculos de linha de visão executados, nós visitados nas buscas de caminho e ações geradas e avaliadas pela IA; o custo total é a soma dos três. A medição é ativada exclusivamente durante a fase de decisão do agente da vez — mede-se o custo de decidir, não o de executar. Operações contadas são invariantes: o mesmo experimento produz exatamente os mesmos custos em qualquer computador, tornando os resultados auditáveis e comparáveis.

4.5. Aprendizado entre partidas

Dentro de um lote, a mesma instância de IA disputa todas as partidas e recebe, ao final de cada uma, a pontuação obtida (+3 vitória, -1 empate, -3 derrota). A IA heurística usa esse sinal para calibrar seus pesos por subida de encosta: joga uma janela de 25 partidas com uma configuração, mede a média de pontos e a adota se superar a melhor média conhecida, revertendo caso contrário; a janela seguinte testa uma perturbação da melhor configuração, com gerador semeado — todo o processo é reprodutível. Ao final do lote, a evolução completa é gravada em arquivo próprio (aprendizado.csv), apresentado junto aos resultados, e as instâncias são descartadas: cada lote parte do zero. Os modelos aleatório e reativo não possuem parâmetros ajustáveis e servem de contraste estático.

4.6. Modelos de tomada de decisão

Quatro modelos são comparados, em níveis crescentes de uso de informação, conforme a Tabela 1.

Modelo	Usa o estado?	Mecanismo	Aprende?	Papel
Aleatório	Não	Sorteia uma ação válida	Não	Piso de desempenho
Reativo	Parcial	Regras fixas: atacar se vê; senão caçar/explorar	Não	Adversário padrão
Heurístico	Sim	Argmax do valor estratégico multicritério	Pesos (hill-climbing)	Estratégia sem custo
Híbrido (proposto)	Sim	Valor estratégico menos custo ponderado	Pesos e lambda	Contribuição da pesquisa

Tabela 1: Comparativo dos modelos de tomada de decisão
Fonte: elaborado pelo autor (2026).

A IA aleatória enumera as ações válidas do turno e sorteia uma (gerador semeado — mesmo o acaso é reprodutível). A IA reativa segue três regras em cascata: se há inimigo com linha de tiro reta, ataca o mais próximo; se vê inimigo sem linha de tiro, aproxima-se para alinhar; se não vê ninguém, dirige-se à última posição conhecida ou explora — e cumpre também o papel de adversário padrão contra o qual os modelos avaliados jogam. A IA heurística, instância de Utility AI, avalia a cada turno com contato visual todas as posições alcançáveis pela função:

$$\text{ValorEstratégico} = w_1 \cdot \text{Vida} + w_2 \cdot \text{Cobertura} + w_3 \cdot \text{Proximidade} + w_4 \cdot \text{Risco} + \text{Movimentação}$$

onde Vida é a proporção de pontos de vida do agente; Cobertura é a proteção potencial da posição (0; 0,5 leve; 1 pesada); Proximidade é o inverso da distância ao inimigo visível mais próximo; Risco é a fração de inimigos visíveis com linha de visão para a posição (impacto negativo); e Movimentação é um incentivo fixo de deslocamento — +0,2 por célula percorrida e -0,2 se a posição já foi visitada na partida — que garante manobra constante e impede o entrancheiramento passivo. Os pesos atuais ($w_1 = 0,1$; $w_2 = 0,3$; $w_3 = 0,5$; $w_4 = -0,2$) não são arbitrários: foram selecionados por varredura comparativa no banco de calibração de 200 sementes, isolado do banco de teste, e são continuamente refinados pelo aprendizado entre partidas (Seção 4.5), cujo histórico integral acompanha os resultados.

O modelo híbrido proposto — contribuição central da pesquisa — parte da formulação de compromisso entre valor estratégico e custo computacional:

$$\text{ScoreAção} = \text{ValorEstratégico} - \lambda \cdot \text{CustoComputacional}$$

A implementação inicial aplicou essa expressão no nível das ações: cada posição candidata teria descontado o custo, em operações contadas, de avaliá-la. Os experimentos de calibração mostraram que essa aplicação é inócua neste domínio, por duas razões mensuradas. Primeiro, a decomposição do custo revelou que o loop de avaliação posicional responde por

apenas dezesseis por cento do consumo total do agente heurístico, enquanto oitenta e quatro por cento concentra-se na busca de caminho executada a cada turno — de modo que nenhum valor do parâmetro poderia economizar mais que a fração minoritária atingida. Segundo, e mais fundamental: como avaliar qualquer posição custa praticamente o mesmo, o termo subtraído torna-se uma constante idêntica para todas as candidatas e, portanto, não altera qual delas apresenta o maior score. Formalmente, sendo o custo aproximadamente uniforme e igual a k , o argumento máximo de $(\text{Valor} - \lambda k)$ coincide com o argumento máximo de Valor . Esse resultado negativo delimita a condição de aplicabilidade da formulação: a penalização por ação só discrimina quando as ações diferem entre si em custo.

A partir dessa constatação, o modelo foi reformulado aplicando o mesmo compromisso um nível acima, na decisão sobre o próprio procedimento de decisão. O agente delibera — isto é, executa a avaliação posicional completa — se, e somente se, o valor estratégico em jogo compensar o custo previsto da análise:

$$\text{ValorEmJogo} - \lambda \cdot \text{CustoEstimado} > 0$$

O ValorEmJogo é estimado pelo produto do número de inimigos visíveis pela soma de dois fatores normalizados: a proximidade, dada pelo inverso da distância ao inimigo mais próximo, e a vulnerabilidade, dada pela fração de vida já perdida — grandezas que crescem justamente nas situações em que decidir bem tem maior consequência. O CustoEstimado é o produto do número de posições candidatas pelo custo unitário de avaliação. Quando não há inimigos à vista, o valor em jogo é nulo e a análise nunca se justifica.

Essa formulação confere ao parâmetro de troca o comportamento de espectro previsto na fundamentação teórica: com valor igual a zero o agente delibera sempre, reproduzindo a IA Heurística pura; com valor suficientemente alto nunca delibera, aproximando-se da IA Reativa; e valores intermediários percorrem o compromisso entre ambos. A calibração conduzida no banco de duzentas sementes adotou o valor de 0,005, correspondente ao joelho da curva de compromisso.

Quando a deliberação não se justifica, o agente opera em regime econômico: desloca-se por passo guloso na direção do objetivo, verificando apenas as células do próprio caminho — três a seis operações — em vez de expandir toda a vizinhança alcançável, o que exige cerca de vinte e cinco. Caçar uma posição já vista, por constituir aproximação com propósito, mantém a busca completa; apenas a exploração às cegas recorre ao passo guloso. A economia é efetivamente medida, e não presumida: cada verificação do passo guloso é

contabilizada pelo mesmo instrumento que mede as demais operações, e o caminho traçado é validado em tempo constante por passo, sem repetição da busca.

4.7. Métricas de avaliação

Para cada modelo, sobre o conjunto de partidas de um lote, calculam-se: WinRate (fração de vitórias); DamageRatio, com limitador contra divisão por zero:

$$\text{DamageRatio} = \frac{\text{dano causado}}{\max(\text{dano recebido}, \varepsilon)}, \quad \varepsilon = 1$$

CoverUsage (fração dos turnos em que o agente terminou em posição com cobertura adjacente); TurnsToVictory (média de turnos para vencer, com empates penalizados pelo valor máximo de 100 e derrotas excluídas); e CustoComputacionalMedio (média por partida das operações contadas na decisão). Cada partida atribui ainda uma pontuação: +3 por vitória, -1 por empate e -3 por derrota. O empate é deliberadamente penalizado porque um modelo que apenas sobrevive sem decidir a partida não demonstra eficácia estratégica; a média de pontos por partida (faixa -3 a +3) mostrou-se a métrica mais legível para comparação direta. As dimensões individuais são agregadas no escore composto:

Para que os pesos correspondam de fato à importância pretendida, todos os termos são previamente normalizados ao intervalo entre zero e um, de modo que o próprio escore pertence a esse intervalo:

$$\text{StrategicScore} = 0,30 \cdot \text{WinRate} + 0,20 \cdot \text{DamageNorm} + 0,20 \cdot \text{CoverUsage} + 0,20 \cdot \text{EfTurnos} + 0,10 \cdot \text{EfCusto}$$

$$\text{DamageNorm} = \frac{\text{DamageRatio}}{1 + \text{DamageRatio}} \quad \text{EfTurnos} = \frac{100 - \min(\text{TurnsToVictory}, 100)}{100}$$

$$\text{EfCusto} = \frac{C_{ref}}{C_{ref} + \text{CustoComputacionalMedio}}, \quad C_{ref} = 1000$$

Na prática, a fórmula é uma definição operacional de jogar bem: vencer (30%), dominar a troca de dano (20%), usar o terreno (20%), decidir a partida rapidamente (20%) e decidir barato (10%). A normalização por saturação do DamageRatio dispensa teto arbitrário — vale 0,5 quando o agente causa exatamente o dano que recebe e tende a um conforme domina a troca; a eficiência de turnos expressa a fração do orçamento de turnos economizada; e a eficiência de custo vale 0,5 quando o modelo gasta exatamente o custo de referência, adotado como a ordem de grandeza típica observada.

Registra-se que a formulação inicial somava as grandezas sem normalização, o que fazia os pesos nominais divergirem do efeito real: medido no confronto triplo do benchmark, o termo de dano contribuía com valores entre 0,85 e 1,12, enquanto o custo contribuía com 0,0002 — cerca de quatro mil vezes menos que os dez por cento previstos. A métrica media, na prática, quase exclusivamente a razão de dano, e era insensível à eficiência computacional, dimensão central desta pesquisa. A correção incide apenas sobre a escala dos termos, preservando exatamente os pesos definidos no projeto, o que afasta qualquer possibilidade de ajuste da métrica em favor do modelo proposto. Como a alteração recai sobre a agregação e não sobre a coleta, os escores de todas as execuções foram recalculados a partir dos dados brutos preservados, sem repetição de simulações.

4.8. Protocolo experimental

Dois bancos congelados e disjuntos de sementes foram gerados uma única vez por um gerador congruente linear documentado: 200 sementes de calibração, usadas exclusivamente para ajuste de pesos e de lambda, e 1000 sementes de benchmark, reservadas à avaliação — a separação previne sobreajuste e os arquivos são imutáveis e versionados. Três mecanismos garantem que diferenças de desempenho sejam atribuíveis aos modelos: sorteio de setores de nascimento (vantagem de terreno), rotação uniforme de iniciativa (vantagem de primeiro turno) e combate determinístico (variância de sorte).

A campanha de coleta segue etapas ordenadas, cada uma com 1000 partidas documentadas: (1) autoconfronto por modelo — três instâncias do mesmo modelo por partida —, caracterizando o comportamento decisório de cada um isoladamente; (2) confronto misto, com um agente de cada modelo; (3) análise das métricas decisórias e identificação dos melhores comportamentos; (4) construção do modelo híbrido a partir do que os dados mostrarem; (5) avaliação final do híbrido contra cada modelo e contra os melhores identificados, verificando a hipótese de superioridade em eficácia e custo. Todas as execuções usam o mesmo banco de 1000 sementes, garantindo comparabilidade integral. O pipeline é determinístico de ponta a ponta — mesma semente, mesmos modelos, mesmos parâmetros produzem partidas byte a byte idênticas, propriedade verificada por reexecução integral de lotes.

4.9. Arquitetura e infraestrutura experimental

O software separa estritamente as responsabilidades: o núcleo de simulação não conhece a lógica das IAs; cada IA implementa um contrato único — receber o estado e devolver uma ação — e a simulação valida e aplica a ação devolvida. Trocar o modelo de um jogador é uma operação de um argumento de linha de comando, garantindo que todos os modelos joguem exatamente o mesmo jogo. Cada lote gera uma pasta autodocumentada e imutável contendo o manifesto da execução (condições completas), o registro por partida (uma linha por jogador, com métricas brutas, derivadas e custo aberto por tipo de operação), o resumo agregado (médias, desvios-padrão e escore), o registro do aprendizado janela a janela e, opcionalmente, o registro turno a turno. Um lote de 1000 partidas executa em 70 a 120 segundos em modo headless. O código, os bancos de sementes e as execuções oficiais são versionados em repositório público.

5. RESULTADOS

Esta seção apresenta os resultados do benchmark oficial, conduzido sobre o banco de mil sementes reservado à avaliação, totalizando sete mil partidas distribuídas em sete execuções: quatro autoconfrontos, em que os três agentes de uma mesma partida executam o mesmo modelo, e três confrontos diretos, em que o modelo proposto enfrenta oponentes de custo pleno. Todas as execuções são determinísticas e estão integralmente documentadas no repositório público do trabalho.

5.1. Validação da neutralidade do ambiente

Antes de comparar modelos, validou-se o instrumento de medição. Executando mil partidas com os três agentes controlados pelo mesmo modelo, um ambiente neutro deve produzir taxas de vitória estatisticamente indistinguíveis, pois qualquer assimetria sistemática denunciaria viés de terreno, de cor ou de ordem de jogada. A Tabela 2 apresenta o resultado do autoconfronto da IA Reativa.

Agente	WinRate	Custo computacional	Strategic Score
Verde	0,306	439	0,469
Vermelho	0,328	444	0,478
Azul	0,301	429	0,470

Tabela 2: Validação de neutralidade — três agentes idênticos (IA Reativa), mil partidas
Fonte: elaborado pelo autor (2026).

Com mil observações e probabilidade de referência de um terço, a flutuação estatística esperada é de aproximadamente um ponto e meio percentual, e a maior diferença observada situa-se nessa faixa. Conclui-se que o sorteio de setores de nascimento e a rotação de

iniciativa neutralizam com sucesso os vieses previstos, e que as diferenças de desempenho observadas adiante são atribuíveis aos modelos, não ao ambiente.

5.2. Caracterização por autoconfronto

Em condições simétricas, a taxa de vitória converge para aproximadamente um terço em qualquer modelo funcional; o que a comparação revela é o preço computacional pago por esse desempenho e a capacidade de conduzir a partida a uma decisão. A Tabela 3 apresenta os resultados.

Modelo	WinRate	Dano	Cobertura	Turnos	Empates	Custo	Escore
Aleatória	0,000	1,14	0,051	100,0	100%	2323	0,145
Reativa	0,312	5,71	0,052	35,5	6,5%	437	0,473
Heurística	0,295	4,55	0,096	45,1	11,6%	777	0,438
Modelo Proposto	0,314	5,18	0,104	29,3	5,7%	379	0,497

Tabela 3: Autoconfronto — mil partidas por modelo

Fonte: elaborado pelo autor (2026).

A IA Aleatória confirma-se como piso absoluto de desempenho: não venceu uma única das mil partidas, encerrando todas por esgotamento do limite de turnos, e o fez pagando o maior custo computacional de todo o estudo. Enumera exaustivamente as ações disponíveis a cada turno e descarta a informação obtida — custo sem benefício, que a pontuação de partida capta corretamente ao penalizar o empate. Seu escore de 0,145 a separa nitidamente dos modelos funcionais, situados entre 0,438 e 0,497.

O modelo proposto obtém o maior escore estratégico do estudo, 0,497, à frente da IA Reativa, com 0,473, e da IA Heurística, com 0,438, liderando quatro das cinco dimensões avaliadas: taxa de vitória, uso de cobertura, rapidez para decidir a partida e economia computacional. Exige 379 operações por partida contra 437 da reativa e 777 da heurística, uma redução de cinquenta e um por cento em relação a esta última. É também o modelo mais decisivo, com apenas 5,7% de empates contra 11,6% da heurística — modelos mutuamente cautelosos tendem a se anular até o limite de turnos — e o mais rápido a concluir as partidas que vence, com 29,3 turnos em média. Em eficiência estratégica, expressa em vitórias por mil operações, entrega 0,829 contra 0,714 da reativa e 0,380 da heurística, mais que o dobro do rendimento desta última por unidade de processamento.

5.3. Confronto direto

A Tabela 4 apresenta o confronto entre os três modelos analíticos na mesma partida, disputado ao longo de mil cenários.

Métrica	Modelo Proposto	Heurística	Reativa
Pontuação média	-1,44	-0,75	-0,81
WinRate	0,225	0,339	0,330
DamageRatio	4,23	5,21	5,61
CoverUsage	0,096	0,095	0,074
Turnos até a vitória	44,4	39,8	39,3
Custo computacional	510	719	484
Eficiência (vitórias/mil ops)	0,441	0,472	0,682
Strategic Score	0,426	0,467	0,472

Tabela 4: Confronto direto entre os três modelos analíticos
Fonte: elaborado pelo autor (2026).

O padrão repete-se nos confrontos contra dois oponentes idênticos: diante de duas instâncias da heurística, o modelo proposto obtém taxa de vitória de 0,232 com custo de 492 operações, contra 0,332 e 0,329 dos adversários, que gastam cerca de setecentas; diante de duas instâncias da reativa, obtém 0,248 com custo de 505. Em competição direta, portanto, o modelo proposto vence menos que ambos os modelos de referência, ainda que preserve o menor custo entre os modelos analíticos e registre o maior aproveitamento de cobertura do confronto triplo.

5.4. Discussão

Os resultados sustentam três conclusões, que convém enunciar com precisão.

A hipótese de eficiência confirma-se. O modelo proposto reduz o custo computacional em mais da metade em relação à heurística pura e constitui o modelo funcional mais econômico do estudo. Em condições simétricas entrega o maior score estratégico observado, vencendo mais, usando mais o terreno, decidindo as partidas mais rapidamente e com a menor taxa de empates, tudo por uma fração do processamento. A formalização explícita do compromisso entre valor estratégico e custo computacional produz, portanto, um agente mensuravelmente mais eficiente, e o parâmetro de troca permite percorrer esse compromisso de forma monotônica e previsível.

A hipótese de superioridade competitiva não se confirma. Quando enfrenta adversários que pagam integralmente o custo da análise, o modelo proposto obtém taxas de vitória próximas de 0,23, contra aproximadamente 0,33 dos modelos de referência. A economia obtida ao deliberar seletivamente tem preço: nos turnos em que opta pelo regime econômico, o agente ocasionalmente deixa de encontrar a posição que a avaliação completa teria identificado, e oponentes que deliberam sempre exploram essa diferença ao longo da partida.

A IA Reativa revela-se um modelo de referência notavelmente robusto. Com 484 operações e taxa de vitória de 0,330 no confronto triplo, apresenta a maior eficiência entre os modelos em competição direta. Este é um resultado relevante em si mesmo: em ambientes

táticos caracterizados por percepção limitada e horizonte curto de consequências, regras simples e bem escolhidas mostram-se difíceis de superar, e a sofisticação analítica precisa justificar o custo que impõe — o que nem sempre ocorre.

Em síntese, o trabalho não demonstra que o modelo proposto seja o melhor jogador em confronto direto; demonstra, com evidência quantitativa obtida em sete mil partidas controladas, que existe um compromisso mensurável e controlável entre qualidade estratégica e custo computacional, que esse compromisso pode ser explicitado como parâmetro de projeto, e que sob avaliação multidimensional em condições simétricas o modelo proposto apresenta o melhor desempenho global do conjunto avaliado.

6. CONCLUSÃO

Este trabalho desenvolveu um simulador tático bidimensional para avaliação sistemática de estratégias de inteligência artificial e propôs um modelo híbrido de tomada de decisão que equilibra valor estratégico e custo computacional, medido de forma independente de hardware por contagem de operações.

Do ponto de vista do instrumento, o resultado é um ambiente controlado, determinístico e integralmente reproduzível, cuja neutralidade foi empiricamente verificada, acompanhado de uma infraestrutura experimental capaz de executar e documentar mil partidas em poucos minutos. Todo o material — código, bancos de sementes, execuções e dados brutos — encontra-se publicamente disponível, permitindo verificação independente.

Do ponto de vista do modelo, verificou-se que a formulação direta do compromisso, aplicada à escolha entre ações, é inócua neste domínio: como avaliar posições distintas custa aproximadamente o mesmo, o termo de penalização torna-se constante e não altera a decisão. A reformulação que se mostrou produtiva desloca o compromisso para a decisão sobre o próprio procedimento — deliberar ou não deliberar —, conferindo ao parâmetro de troca um comportamento de espectro entre a heurística completa e a reação simples.

Quanto à hipótese, os resultados confirmam o ganho de eficiência e não confirmam o ganho de eficácia competitiva. O modelo proposto opera com pouco mais da metade do custo da heurística, apresenta a maior eficiência estratégica e o maior score composto em condições simétricas, mas obtém menos vitórias quando enfrenta adversários que pagam integralmente o custo da análise. A contribuição científica do trabalho reside, assim, menos na superioridade de um modelo particular e mais na demonstração quantitativa de que o

compromisso entre qualidade e custo é mensurável, controlável e explicitável como decisão de projeto.

Como trabalhos futuros, apontam-se três direções. A primeira é a investigação de critérios adaptativos para o parâmetro de troca, ajustando-o ao longo da partida conforme a fase do confronto, em vez de mantê-lo fixo. A segunda é a extensão do estudo a ambientes de maior escala, em que o custo da busca cresce e a economia proporcionada pelo regime econômico tende a se ampliar. A terceira é a comparação com modelos de busca em profundidade, como o Monte Carlo Tree Search, empregado neste trabalho apenas como referência teórica, o que permitiria estender a curva de compromisso à região de alto custo e alta qualidade.

7. CRONOGRAMA

Atividade	Ja n	Fe v	M ar	A br	M ai	Ju n	Ju l	A go	Se t	O ut	N ov	De z
Projeto e revisão de literatura	X	X	X	X								
Simulador (Fases 1-2)			X	X	X	X	X					
Modelos básicos de IA						X	X					
Campanha de coleta							X	X				
Análise intermediária								X				
Modelo híbrido e calibração									X			
Avaliação final (benchmark)									X	X		
Escrita do TCC e artigos							X	X	X	X	X	X

Fonte: elaborado pelo autor (2026).

8. ORÇAMENTO FINANCEIRO

Este trabalho utiliza exclusivamente ferramentas gratuitas e de código aberto (motor Godot, linguagem GDScript, Python para análise, Git para versionamento) e equipamentos já disponíveis, não sendo necessário orçamento extra.

9. DISSEMINAÇÃO DOS RESULTADOS

Este trabalho poderá ser publicado pelo menos na Jornada Científica e Tecnológica do IFSULDEMINAS. Adicionalmente, o simulador, os bancos de sementes, as execuções oficiais e toda a documentação são mantidos em repositório público (github.com/madeiragab/tcc-simulador-ia), permitindo verificação independente e reutilização por outras pesquisas.

10. REFERÊNCIAS BIBLIOGRÁFICAS

BROWNE, C. B. et al. **A Survey of Monte Carlo Tree Search Methods**. IEEE Transactions on Computational Intelligence and AI in Games, v. 4, n. 1, p. 1-43, 2012.

GODOT ENGINE. **Godot Engine Documentation**. 2026. Disponível em: <<https://docs.godotengine.org>>. Acesso em: 21/07/2026.

MARCOTTE, R.; HAMILTON, H. J. **Behavior Trees for Modelling Artificial Intelligence in Games: A Tutorial**. The Computer Games Journal, v. 6, p. 171-184, 2017.

MARK, D.; DILL, K. **Improving AI Decision Modeling Through Utility Theory**. In: Game Developers Conference, 2010, São Francisco. GDC Vault, 2010.

MILLINGTON, I.; FUNGE, J. **Artificial Intelligence for Games**. 2. ed. Boca Raton: CRC Press, 2016.

PÉREZ-LIÉBANA, D. et al. **General Video Game AI: A Multitrack Framework for Evaluating Agents, Games, and Content Generation Algorithms**. IEEE Transactions on Games, v. 11, n. 3, p. 195-214, 2019.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 3. ed. Upper Saddle River: Pearson, 2010.

Muzambinho, 21 de julho de 2026.

APÊNDICE A – ESTRUTURA DOS DADOS COLETADOS

Cada execução de lote gera uma pasta imutável com carimbo de data e hora contendo os arquivos descritos a seguir, todos em formatos abertos (texto e CSV).

manifest.txt — condições da execução: data e hora, versão do motor, banco e faixa de sementes, regra de rotação de iniciativa, modelo de IA de cada jogador, constantes de jogo (dano base 30; reduções 10/20; limite 100 turnos; movimento 3; vida 100; visão 8; cone 120 graus), parâmetros de IA e duração.

partidas.csv — uma linha por jogador por partida: identificador, semente, jogador que iniciou, jogador, modelo, vencedor, indicador de vitória, pontos (+3/-1/-3), turnos, dano causado e recebido, DamageRatio, CoverUsage, custo total e custo aberto por tipo de operação (linha de visão, nós de busca, ações avaliadas).

resumo.csv — agregados por jogador: partidas, pontuação total e média, WinRate, DamageRatio e CoverUsage (média e desvio-padrão), TurnsToVictory, Efficiency, custo médio e desvio, StrategicScore.

aprendizado.csv — evolução do aprendizado janela a janela: pesos testados, média de pontos da janela e decisão (adotado/revertido).

turnos.csv (opcional) — registro fino turno a turno: ação escolhida, posição, proteção por cobertura e inimigos visíveis de cada agente.

APÊNDICE B – CORRESPONDÊNCIA COM OS APONTAMENTOS DA BANCA

O quadro abaixo mapeia cada apontamento da banca de qualificação para a seção deste documento que o responde.

Apontamento	Resposta
Não seguiu o modelo padrão de pré-projeto da instituição	Documento reestruturado integralmente conforme o modelo institucional (capa, Informações Gerais, seções 1-9, cronograma mensal)
Ausência de resultados parciais	Seção 5.1 (neutralidade validada com 1000 partidas; calibração; aprendizado)
Como será medido o custo computacional abstrato	Seção 4.4 (contagem de operações: linha de visão, nós de busca, ações avaliadas)
Jogo existente ou novo? Que gênero?	Seção 4, abertura (jogo novo em Godot; tático por turnos em grade, 3 agentes)
Diferença prática entre os quatro modelos	Tabela 1 e Seção 4.6
O que significa resolução sequencial	Seção 4.3 (um agente por vez sobre estado atualizado; sem simultaneidade)
Como funciona a ordem alternada entre rodadas	Seção 4.3 (rotação determinística: partida i inicia pelo agente $i \bmod 3$)
Como foi definido o limite de 100 turnos	Seção 4.3 (empírico: durações médias de 30-90 turnos; teto de segurança)
O que conta como cobertura	Seção 4.3 (célula de cobertura; proteção direcional; leve -10, pesada -20)
Quantos agentes por equipe; controle por turno	Seções 4.2 e 4.3 (3 agentes independentes, sem equipes; um por vez)
Dois agentes podem atacar o mesmo alvo?	Seção 4.3 (adversários independentes; cada um decide em seu turno)
Há aprendizado entre partidas?	Seção 4.5 (subida de encosta por janelas; registro em arquivo; reset por lote)
Origem dos pesos da heurística ($w1..w4$)	Seção 4.6 (varredura no banco de calibração + aprendizado; valores atuais)
O que o Strategic Score representa; por que esses pesos	Seção 4.7 (definição operacional de jogar bem; pesos a priori; limitação registrada)
O mapa 40x40 foi testado?	Seções 4.1 e 5.1 (validado: durações, neutralidade, escala de lote)

Quadro 1: Apontamentos da banca e seções correspondentes

Fonte: elaborado pelo autor (2026).