



**MINISTÉRIO DA EDUCAÇÃO
SECRETARIA DE EDUCAÇÃO PROFISSIONAL E TECNOLÓGICA
INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO SUL DE MINAS GERAIS
CIÊNCIA DA COMPUTAÇÃO**

Projeto de Trabalho de Conclusão de Curso

Análise das Aplicações de Ciência de Dados Para o Desempenho Escolar

Ciências Exatas e da Terra, Ciências da Computação e Metodologia e Técnicas da
Computação

2020

Muzambinho – MG

INFORMAÇÕES GERAIS

Título do projeto: Análise das Aplicações de Ciência de Dados Para o Desempenho Escolar

Orientador(a) - Nome: Aline Marques Delvalle

E-mail: aline.valle@muz.ifsuldeminas.edu.br

Endereço no Lattes: <http://lattes.cnpq.br/1961580945745420>

Discente - Nome: Lucas José Serra Matthes

E-mail: l.j.s.matths@gmail.com

Endereço no Lattes: <http://lattes.cnpq.br/1415488314875166>

Membros do projeto:

Nome	Titulação máxima	Instituição Pertencente	Função	E-mail
Lucas José Serra Matthes	Graduando com Ciência da Computação	IFSULDEMINAS - Campus Muzambinho	Autor	l.j.s.matths@gmail.com
Aline Del Valle	Mestre em Ciência da Computação	IFSULDEMINAS - Campus Muzambinho	Orientadora	aline.valle@muz.ifsuldeminas.edu.br
Gisselida do Prado Siqueira	Pós graduação em Ciência da Computação	IFSULDEMINAS - Campus Muzambinho	Co orientadora	gisselida.siqueira@muz.ifsuldeminas.edu.br

Local de Execução: IFSULDEMINAS – Campus Muzambinho.

Período de Execução:

Início: Fevereiro/2020

Término: Dezembro/2020

1. ANTECEDENTES, CARACTERIZAÇÃO DO PROBLEMA E JUSTIFICATIVA

Atualmente, há uma infinidade de dados disponíveis, a partir dos quais novas informações e conhecimentos podem ser obtidos, servindo de embasamento para a tomada de decisões.

Com essa dinâmica de inúmeros dados à disposição, tendo maior enfoque nos dados educacionais, Motta (2016) cita que eles podem ser encontrados no Instituto Nacional de Estudos e Pesquisas Anísio Teixeira, INEP, que possui uma base consistente de dados reais de alunos sendo atualizada anualmente. Nesta base, é possível encontrar diversas informações, como os materiais das instituições de ensino, volume de alunos, características administrativas dos docentes, número de matrículas, movimento escolar, edificações e equipamentos existentes.

Frequentemente, também são usados os Ambientes Virtuais de Aprendizagem (AVA). Segundo Kampff, Reatege e Lima (2008), os AVAs podem armazenar um histórico de todas as ações dos alunos, seus acessos, participações em fóruns, respostas de questionários, envio de arquivos, dentre outros, sendo mais uma fonte de dados.

Com o avanço na área de pesquisa da informação, o grande volume de dados acadêmicos disponíveis passaram a ser usados e trabalhados na mineração de dados educacionais (do inglês “*Educational Data Mining*”, ou ESM) (PAZ e CAZELLA, 2017). A mineração de dados educacionais, campo da Ciência de Dados (do inglês “*Data Scientist*”, ou DS), tem como objetivo analisar grande quantidade de dados, prepará-los e estabelecer relações entre eles, gerando informações e conhecimentos utilizados para a tomada de decisões, correção e criação de produtos mais inovadores, por exemplo.

Podem-se encontrar trabalhos neste contexto, Barros *et al.* (2020) aplicaram ESM a fim de encontrar relações no desempenho do aluno nas disciplinas do primeiro período com a disciplina de Lógica Matemática, ofertada no segundo período. Com esses dados a instituição pôde propor medidas a fim de diminuir a retenção de alunos, uma vez que a disciplina de Lógica tem uma importância significativa para o curso. Manhães e Cruz (2019) usaram uma arquitetura, denominada WERE, para oferecer a predição dos discentes que estão em risco de abandonar o sistema acadêmico. Pascoal, Brito e Regê (2015) usaram a ESM para previsão de

desempenho dos estudantes nas disciplinas de programação do curso de Ciência da Computação.

Mecanismos que permitam prever o aproveitamento discente são úteis no ambiente educacional por conseguirem uma resposta mais rápida para a instituição e possibilitarem que ações preventivas possam ser tomadas no caso de uma predição de reprovação. Estratégias e atitudes podem ser elaboradas para auxiliar discentes, professores e instituições de ensino na recuperação do aluno, na melhoria da qualidade de ensino e na economia de dinheiro público com gastos desnecessários. Além disso, os gestores acadêmicos contam com poucas ferramentas para auxiliar na identificação de quais alunos estão em risco de evasão ou retenção (MANHÃES, 2015).

Considerando a instituição que servirá como objeto deste estudo, pode-se encontrar indicadores institucionais relacionados à temática no Anuário Educacional Estatístico do IFSULDEMINAS de 2019. O anuário traz o índice de eficiência acadêmica, “este indicador mede o percentual de alunos que concluíram o curso com êxito dentro do período previsto (+ 1 ano)[...]” (MORAIS *et al.*, 2019). De acordo com este índice, o percentual de concluintes da instituição foi de 32.32%, de evadidos 66.13% e de matriculados classificados como retidos de 1.55%, todos esses percentuais são referentes ao ciclo de matrículas finalizadas em 2017. A retenção está diretamente relacionada ao aproveitamento discente, já a evasão pode estar relacionada à reprovação em componentes curriculares.

Sendo assim, este projeto tem por objetivo analisar as condições em que o aluno terminou as suas disciplinas do primeiro módulo dos cursos Técnico em Informática, modalidades presencial e EAD (Educação a Distância) do IFSULDEMINAS, Campus Muzambinho, e prever se o aluno terá sucesso ou estará com risco de retenção nas disciplinas do segundo módulo do curso. Para isso, serão utilizados algoritmos de classificação de mineração de dados e elencadas as suas capacidades de predição.

2. REFERENCIAL TEÓRICO

2.1. Cursos Técnicos Subsequentes

De acordo com Gomes (2018), os cursos técnicos subsequentes foram criados para serem ofertados aos indivíduos que concluíram o Ensino Médio ou equivalente e que também

não estejam matriculados em nenhum curso da instituição de ensino. Eles possuem duração média de 4 semestres, geralmente com as inscrições do processo seletivo sendo gratuitas. Ainda segundo o autor, para os cursos EAD, “[...] 7% das instituições que ofereceram cursos da categoria citada registraram uma taxa de evasão na faixa de 51% e 75%”.

Abordando a instituição estudada neste projeto, o IFSULDEMINAS - Campus Muzambinho oferta cursos técnicos subsequentes na modalidade presencial em Administração, Agropecuária, Contabilidade, Meio Ambiente, Enfermagem, Informática e Segurança do Trabalho. E, na modalidade EAD, curso técnicos subsequente em Informática, Cafeicultura, Meio Ambiente e Vigilância em Saúde.

O curso Técnico Subsequente em Informática foi criado em 1998, com intuito de oferecer um curso técnico no período noturno, com carga horária de 1210 horas, acrescentando também 150 horas de estágio, mantendo o foco no eixo tecnológico de informação e comunicação. O curso visa formar profissionais com conhecimentos tecnológicos voltados para as áreas de manutenção de redes e de computadores e desenvolvimento de sistemas, sendo capaz de aplicar estes conhecimentos de forma profissional e ética (PPC, 2016).

Segundo o Projeto Pedagógico do Curso Técnico em Informática da modalidade EAD de 2019, o curso tem duração de 2 módulos letivos e contém a carga horária completa de 1200 horas (PPC, 2019). O curso segue as orientações do Catálogo Nacional de Cursos Técnicos para capacitação, com objetivo de incluir alunos por meio da educação a distância, promovendo a ampliação do conhecimento técnico na área da Informática.

2.2. Mineração de Dados

Para predizer rótulos, determinar ou encontrar padrões, assim como regras de associações, existe um processo de exploração que busca encontrar relacionamentos entre dados, que é chamado de Mineração de Dados.

Carvalho (2018) cita três tarefas principais da Mineração de Dados: “a predição, agrupamentos de dados e associação ou descoberta de regras de associação, e que trabalhando juntas podem compor muitas variações e até permitir a criação de subtarefas na resolução dos problemas”.

A mineração de dados surgiu da imersão da economia de informação, que visava a informação como uma espécie de mercadoria. Entretanto, as pessoas não tinham conhecimentos suficientes para extrair informações prévias e melhorar as decisões gerenciais.

Logo, o processo de mineração de dados envolve grandes volumes de dados e disciplinas como Computação, Matemática e Estatística integradas com diversas áreas de conhecimentos (CORADINE, 2011).

Uma área da mineração de dados é a que trata de dados educacionais. Hoje existem vários dados escolares contidos em AVAs e plataformas de ensino digitais, é possível trabalhar com atributos extraídos destas bases e analisar suas correlações.

O objetivo da mineração de dados educacionais é extrair informações e conhecimentos que muitas vezes não podem ser encontrados devido à quantidade de dados disponíveis, para ajudar a resolver problemas como evasão e retenção escolar, ou desempenho e rendimento acadêmico, por exemplo. Para isso são utilizadas metodologias, técnicas e algoritmos (KAMPFF, REATEGE e LIMA, 2008).

2.3. KDD

De acordo com Furlan (2018), resultados das aplicações de mineração de dados podem ser obtidos por meio da metodologia KDD (*Knowledge Discovery in Databases*). Dentre as etapas fundamentais do processo KDD, Sales e Gomes (2014) citam: seleção, pré-processamento, transformação, data mining e interpretação. A figura 1 mostra as etapas do KDD.




Figura 1: Fases KDD.

Fonte: SALES e GOMES, 2014.

Detalhando o processo KDD, a etapa de seleção tem o intuito de separar variáveis/ atributos relevantes do tema abordado, servindo de entrada de dados para os algoritmos de mineração de dados e estabelecendo as dimensões a serem aplicadas nestes algoritmos.

O pré-processamento envolve a captação, a organização e o tratamento de dados. Essa etapa tem as funções de identificar dados desnecessários, limpar, codificar e enriquecer dados de modo a não apresentarem inconsistências ou erros, tendo o objetivo de organizar os dados brutos para obter o grupo de dados que será trabalhado (RAMOS *et al.* 2018).

A transformação, como o próprio nome diz, transforma as informações para que as implementações ligadas à ciência de dados possam ser aplicadas. É construída com base nos dados pré-processados para que as etapas posteriores possam ser realizadas, convertendo os dados antigos em um novo modelo/base (SANTOS, 2017).

A mineração de dados é a parte mais importante do KDD, consiste no uso de variadas técnicas e algoritmos a partir da base transformada, com o principal objetivo de extrair e buscar conhecimento em quantidades enormes de dados. Os algoritmos podem ser preditivos (supervisionado), trabalhando com classificação ou regressão, ou descritivos (não supervisionado), trabalhando agrupamento, associação ou sumarização (FACELLI *et al.*, 2011).

A última etapa do KDD é a avaliação dos resultados obtidos pelos algoritmos, ou pós-processamento, que consiste em analisar os resultados a fim de entendê-los e encontrar conhecimentos. Técnicas de visualização podem ser utilizadas para facilitar esse entendimento dos resultados.

Segundo Motta (2016), encontram-se na literatura diversos algoritmos de mineração de dados que podem ser utilizados para classificação ou técnicas para o uso nas etapas de mineração de dados:

- Classificadores: Naive Bayes; KNN (k - vizinhos mais próximos); SVM (Support Vector Machine); Árvores de Decisão ou Classificação (C4.5); Redes Neurais Artificiais (Multilayer Perceptron); etc.
- Medidas de desempenho para classificação supervisionada: matriz de confusão; taxas; acurácia da classificação; validação cruzada; etc.

2.4. Algoritmos de Mineração de Dados

2.4.1. KNN (K Nearest Neighbors)

Segundo Fazolin (2017), o KNN é um algoritmo que baseia-se em uma função que calcula distâncias entre as instâncias do problema e os k centróides para rotular novos objetos. Achando os k centróides mais próximos a um objeto é possível fazer uma classificação ou regressão.

Esse algoritmo pode ser implementado facilmente. Após o treinamento imposto pela técnica de aprendizado, que treina a base de dados para assim encontrar os k vizinhos mais próximos, é possível conseguir uma predição (regressão ou classificação) com os dados da instância.

2.4.2. SVM

O algoritmo SVM, do inglês *Support Vector Machine*, utiliza-se de duas classes para estabelecer uma classificação e uma linha central para representar a separação das mesmas (SILVERIO, 2015). A entrada se divide por dois grupos de dados, sendo uma porcentagem para o treinamento e o restante para teste. O algoritmo calcula a distância do objeto até a linha do centro para a classificação, utiliza também os conceitos de margens otimizadas, vetores de suporte e vetor pontilhado ou central, que ajudam na categorização.

2.4.3 Redes Neurais

O processo de funcionamento das redes neurais se parece muito com o funcionamento dos neurônios do cérebro humano. Elas podem predizer certas informações a partir de dados, para isso devem ser treinadas para o ajuste dos pesos sinápticos, que são as conexões entre os neurônios. Deste modo o conhecimento que vem dos neurônios se dá, pois cada neurônio computa uma função matemática com os valores de entrada, formando as camadas das redes neurais, os cálculos propagam-se entre as camadas até a camada de saída, onde o resultado é obtido (CERRI, 2017).

2.5. Trabalhos Relacionados

Manhães e Cruz (2019) apresentaram a arquitetura WAVE baseada em mineração de dados educacionais. O objetivo era prever quais alunos estavam em risco de abandonar o sistema utilizando apenas dados acadêmicos, permitindo o acompanhamento do desempenho acadêmico dos graduandos durante os semestres. A precisão dos resultados foi em torno de 80%.

Motta (2016), realizou uma revisão bibliográfica e analisou não só diferentes técnicas de classificação, como também de balanceamento e seleção de atributos para predição de desempenho e abandono em universidades. Para isso, o autor utilizou os dados advindos do vestibular e do banco de dados acadêmico da universidade: dados demográficos; sócio-econômicos; e resultados acadêmicos.

Fernandes (2019), estudou a evasão do curso de Ciência da Computação, avaliando o perfil socioeconômico dos alunos por meio dos dados do SISU/ENEM (Sistema de Educação Unificada / Exame Nacional do Ensino Médio), dos anos de 2010 até 2018, e da situação dos alunos matriculados do primeiro ano do curso. Devido ao percentual de 43,87% de abandono, o pesquisa mostrou que “existe um padrão que pode ser mapeado algoritmicamente da evasão na Instituição” (FERNANDES, 2019).

Por meio de técnicas de aprendizagem de máquina, Silverio (2015) apresentou a predição do rendimento escolar de estudantes, utilizando por definição comitês de classificadores para assim aplicar e conseguir um maior nível de acurácia comparado a outros trabalhos.

Gonçalves (2020) propôs identificar alunos com maior risco de evasão, analisando dados dos alunos ingressantes no curso de Administração entre 2014 e 2018. Tentou mostrar a efetividade da escolha dos atributos, executando três experimentos com duas bases - uma com frequência escolar e outra sem. O experimento mostrou um resultado vantajoso, o que explicita que as técnicas que foram usadas podem auxiliar gestores dessa área.

Com a grande quantidade de dados gerados virtualmente em Ambientes de Virtuais de Aprendizagem (AVA), Ramos (2018) utilizou a mineração de dados educacionais para aplicar cinco algoritmos classificadores para prever o risco de evasão em cursos EAD, conseguindo obter acurácia acima de 90%.

Os cursos que envolvem tecnologias têm elevados índices de reprovação, o que acaba

contribuindo com a evasão. Saraiva (2019), trabalhou com técnicas e algoritmos de aprendizagem de máquina em uma base de dados contendo informações acadêmicas e socioeconômicas de 8 anos do curso Técnico em Informática, a fim de identificar estudantes em situação de risco de evasão, incentivando a instituição a realizar ações de permanência e o êxito do discente.

Para Santana (2014), a modalidade semipresencial e os AVAs produzem dados educacionais relevantes. Santana (2014), utilizou dados do AVA e mineração de dados educacionais para classificação em 3 classes relativas à notas em um primeiro experimento e nas classes aprovado/reprovado em um segundo experimento, levando em conta as variáveis de rendimento dos alunos. O trabalho deu embasamento para tomada de decisão por parte de professores e gestores e os algoritmos obtiveram resultados com até 74% de acurácia.

Fazolin (2017) propôs a utilização de mineração de dados educacionais para identificação de padrões que pudessem ajudar na tomada de decisões. O objetivo foi de auxiliar a previsão de evasão de alunos do Ensino Fundamental em escolas particulares, sendo tratado como um problema de classificação.

As disciplinas relacionadas à programação tendem a ter um baixo rendimento dos estudantes, o que preocupa vários gestores e diretores. Esse baixo rendimento pode estar relacionado ao aumento da evasão. Pascoal (2015) estudou os estudantes prováveis ao fracasso nas disciplinas iniciais de programação de cursos do Centro de Informática. Esse estudo conseguiu, por meio da ciência de dados, encontrar os alunos propícios à evasão utilizando atributos relacionados às disciplinas já cursadas (pré-requisitos). Os algoritmos tiveram uma taxa de acerto superior a de 80% .

Devido alto índice de reprovação na disciplina de Lógica de Programação, Barros (2020), utilizou técnicas de mineração de dados educacionais para conseguir prever o desempenho na disciplina. Os algoritmos desenvolvidos alcançaram acurácia de 77% ao prever o rendimento dos estudantes. O trabalho ajudou a validar que existe um grande índice de reprovação e contribuiu para que os responsáveis pela instituição estudada possam tomar atitudes perante os números apresentados.

3. OBJETIVOS

3.1. Objetivo Geral

Predizer o aproveitamento (aprovado/reprovado) dos discentes do segundo módulo dos cursos Técnicos em Informática Subsequente do IFSULDEMINAS, Campus Muzambinho, modalidade presencial e EAD, por meio de algoritmos preditivos, a fim de melhorar as estratégias e ações que visem a recuperação do aluno, evitando a reprovação.

3.2. Objetivos Específicos

- Implementar e testar diferentes algoritmos de classificação, bem como identificar os que obtiveram os melhores resultados na predição de aproveitamento.
- Proporcionar um ambiente de discussão sobre os cursos Técnicos em Informática Subsequente do IFSULDEMINAS, Campus Muzambinho, nas modalidades presencial e EAD.
- Analisar modelos preditivos que possam ser utilizados como base para identificar risco de reprovação.

4. METODOLOGIA E ESTRATÉGIA DE AÇÃO

Para a execução deste trabalho, inicialmente será feita uma revisão de literatura para o embasamento teórico sobre o tema (item 4.1). Em seguida serão utilizadas as etapas do processo KDD, organizadas da seguinte forma: Seleção, Pré-processamento e Transformação (item 4.2); Mineração de Dados - Algoritmos (item 4.3) e Avaliação (item 4.4).

4.1. Revisão de Literatura

Neste estudo, será realizada inicialmente uma revisão de literatura a fim de identificar e conhecer os principais trabalhos que tenham propósito relacionado ao objetivo deste. Com a revisão de literatura pretende-se extrair os conhecimentos fundamentais da pesquisa, desta forma ela pode ser sustentada por um estudo relevante que permita descobrir quais os algoritmos e variáveis mais utilizados e que alcançaram os melhores resultados.

4.2. Seleção, Pré-processamento e Transformação

Para a aplicação do estudo de predição de aproveitamento serão analisados os dados referentes às turmas dos cursos Técnico em Informática Subsequente do IFSULDEMINAS, Campus Muzambinho, modalidade EAD e presencial. Essa intervenção será feita a partir de dados cedidos pela instituição.

Para a concessão dos dados será feita uma solicitação de autorização de uso à direção da instituição. A partir da autorização, os mesmos serão disponibilizados pelo Núcleo de Tecnologia da Informação (NTI), provavelmente no formato *xls* para melhor manipulação. Para a aplicação de ciência de dados no tema deste trabalho será preciso acesso a dados relacionados ao histórico das disciplinas e às características de alunos e de professores (características de identificação pessoais não serão cedidas, portanto desconsideradas).

Trabalhando com dados a melhor escolha é sempre construir uma base de dados consistente que tenha embasamento sobre o assunto. Os dados acadêmicos disponibilizados serão estudados a fim de entender sua relevância: se eles são balanceados, se existe quantidade de dados suficiente e dados adicionais.

Serão selecionados os atributos relevantes que a revisão de literatura destacar. São exemplos de atributos e variáveis que podem compor a base de dados: modalidade de ensino (EAD, presencial); notas em disciplinas; ano de entrada no curso; ano atual no curso; se o aluno ficou de exame; se ficou de recuperação; disciplina atual; se o professor tem ou não licenciatura; dentre outros.

Os dados selecionados serão integrados e passarão pelo processo de limpeza onde serão tratadas ausência, inconsistência, redundância e/ou ruídos. Em seguida, passarão pela transformação, onde normalizações e conversões de atributos em relação à escala serão feitas.

Para a manipulação de dados será utilizada a linguagem de programação Python e a biblioteca Pandas pois, segundo VanderPlas (2017), conjuntamente, possuem uma boa desenvoltura em ciência de dados, na manipulação de dados heterogêneos e rotulados, permitindo trabalhar de uma forma mais rápida e acessível com arquivos do tipo *txt*, *excel*, *csv*, etc.

A fim de entender melhor os dados será feita uma estatística descritiva, para tanto serão utilizadas as bibliotecas Pandas e Matplotlib. De acordo com Fernandes (2019), a estatística descritiva conduz o estudo por meio das técnicas contidas nas bibliotecas da

linguagem de programação Python como Matplotlib, que trabalha com a plotagem de gráficos, o que melhora a apresentação de resultados.

4.3. Mineração de Dados - Algoritmos

Com base na revisão de literatura, serão empregados os algoritmos mais utilizados nos trabalhos correlacionados e que obtiveram melhores porcentagens de acerto nas suas intervenções, dando maior credibilidade à pesquisa. Poderão ser utilizados os algoritmos KNN, Redes Neurais e SVM, por exemplo.

Na implementação dos algoritmos será utilizada a biblioteca do Python, Scikit-Sklearn, pois, segundo Pedregosa *et al.* (2011), a biblioteca de aprendizagem de máquina possui uma coleção de algoritmos de classificação, agrupamento e regressão implementados e produz códigos eficientes.

4.4. Avaliação

Após a implementação dos algoritmos de classificação, serão colhidas as métricas, matriz de confusão e os relatórios alcançados pelos algoritmos, a fim de avaliar e comparar os resultados obtidos, avaliando a eficácia de cada processo preditivo. Para tanto será utilizada a biblioteca Scikit-Sklearn. O resultado da matriz de confusão ajuda no feedback do comportamento dos algoritmos e os relatórios oferecem a acurácia obtida pelos algoritmos, uma medida de proximidade entre o valor obtido e o valor esperado.

5. RESULTADOS E IMPACTOS ESPERADOS

Espera-se criar um modelo de classificação que seja capaz de relatar se o aluno conseguirá ser aprovado ou reprovado em uma disciplina do segundo módulo do curso Técnico em Informática Subsequente, modalidade EAD e presencial, tendo como pré-requisito seu desempenho no primeiro módulo dos cursos, e identificar dentre os algoritmos utilizados qual obteve a maior eficácia.

5.1 Resultados Preliminares (parciais)

5.1.1. Revisão de Literatura

A Tabela 1 apresenta as variáveis identificadas nos trabalhos da revisão de literatura e a Tabela 2 os objetivos, algoritmos, bem como suas taxas de acertos, destes trabalhos.

Referência	Variáveis
Estudo da evasão de alunos de graduação utilizando Educational Data Mining (FERNANDES, 2019).	11 variáveis representando as disciplinas do primeiro ano do curso de Ciência da Computação, 1 variável referente ao trancamento do semestre e a última variável referente a rotulação da situação dos discentes.
Utilizando comitês de classificadores para predição de rendimento escolar (SILVERIO, 2015).	Grupo 1: cidade, turma, turno, idade, sexo, interesse por informática, por programação, por jogos, por desafios, por estudar, por ler, por disciplinas, por raciocínio lógico, por matemática, por inglês, por aulas exploratórias, por aulas no laboratório, por resolução de exercícios, por questionários, por slides, por vídeos, por pesquisa e por projeto. Grupo 2: quantidade de interações, de atividades, média de notas e status de finalização em quiz; quantidade de postagens e interações em fórum; quantidade de interações, visualizações e logins no moodle; quantidade de visualizações de material.
Mineração de dados e Evasão estudantil: Analisando o curso de nível superior do Ifes (GONÇALVES, 2020).	Sexo, tipo de forma de ingresso, renda familiar, escola de origem, tipo de escola de origem, cidade, frequência, faixa (frequência), cor/raça, idade e faixa (etária).
Um estudo comparativo de classificadores na previsão da evasão de alunos em EAD (RAMOS, 2018).	Média semanal de acessos ao ambiente; quantidade de acessos ao ambiente por turno (Manhã, Tarde e Noite); tempo médio semanal de utilização da plataforma; e quantidade de acessos ao ambiente do aluno por semestre. Quantidade de acessos aos diferentes tipos de atividades; de acessos aos fóruns; e de postagens do aluno em fóruns por disciplina. Quantidade geral de mensagens enviadas; de mensagens recebidas; de colegas diferentes para quem o aluno enviou mensagens; de mensagens dos professores recebidas pelo aluno; de mensagens de colegas recebidas pelo aluno; de mensagens enviadas pelo aluno para outros colegas; e de mensagens enviadas pelo aluno aos professores por semestre. Quantidade geral de recursos; de atividades; e de atividades com prazos de envio definidos por professor por disciplina. Quantidade de fóruns de discussão e de sessões de web conferências

	disponibilizadas no curso por disciplina.
Uma proposta para predição de risco de evasão de estudantes em um curso técnico em informática (SARAIVA, 2019).	Total de aprovado; de aprovado com dependência; de trancados; de aprovado parcialmente; de frequência; e de reprovado. Coeficiente rendimento geral. Turno do estudante. Grau de instrução da mãe. Forma de Ingresso.
Avaliação do Perfil de Uso no Ambiente Moodle Utilizando Técnicas de Mineração de Dados (SANTANA, 2014).	Desempenho final; número total de acesso ao fórum; número total de interações com as vídeo-aulas; número total de interações com o material da disciplina; número total de interações com as apresentações em slides; tempo médio de acesso no ambiente.
Tratamento temporal em mineração de dados educacionais para fidelização de estudantes (FAZOLIN, 2017).	Dependentes matriculados; tipo de aluno; média de idade; gênero; se é adventista; estado civil; grau instrução do responsável; faixa etária; se tem irmão; se veio de outro estado; curso; aluno há quanto tempo; quantidade de alunos; turno; ocorrências boas, material e ruins; se já reprovou; média em Matemática, Religião, Biologia, História, Geografia, Inglês, Português e Educação Física; faltas em Geografia, Inglês, Português e Educação Física; responsável legal é financeiro, mês de início da parcela; bolsa de descontos normalizado; se cobrou matrícula; quantidade de parcelas; rematriculou.
Uma abordagem para a previsão de desempenho de alunos de Computação em disciplinas de programação (PASCOAL, 2015).	Desempenho nas disciplinas (Matemática, Física, Química, Biologia, Geografia, História, Comunicação e Expressão e Língua Estrangeira) da prova de ingresso na instituição (decimal).
Predição do rendimento dos alunos em lógica de programação com base no desempenho das disciplinas do primeiro período do curso de ciências e tecnologia utilizando técnicas de mineração de dados (BARROS, 2020).	Desempenho na disciplina de Lógica de Programação do segundo período. As disciplinas consideradas na análise são: Pré-Cálculo, Cálculo I, Química Geral, Práticas de Leitura e Escrita I, Ciência, Tecnologia e Sociedade e Vetores e Geometria Analítica.
Predição do Desempenho acadêmico de alunos da graduação utilizando mineração de dados (MANHÃES e CRUZ, 2019)	Identificador; identificador de ingresso; identificador de curso; coeficiente de rendimento acadêmico - CRA (média de aproveitamento das disciplinas cursadas durante a graduação); período letivo (ano - semestre); situação da matrícula do estudante no período; coeficiente de rendimento do período cursado; número de disciplinas cursadas em cada período letivo; número

	de disciplinas aprovadas em cada período letivo; média aritmética obtida nas disciplinas aprovadas em cada período letivo; número de disciplinas reprovadas por falta e/ou média em cada período letivo; número de disciplinas reprovadas por média em cada período letivo.
--	---

Tabela 1: Variáveis

Fonte: O autor (2020)

A Tabela 1 apresenta os atributos extraídos da revisão de literatura, onde as principais variáveis que serão utilizadas nesta na pesquisa podem ser correlacionadas com as variáveis encontradas nos trabalhos pesquisados (Tabela 1), como aprovado, com alguma dependência, coeficiente rendimento acadêmico, nota da matéria, quantidade de dependências, modalidade (EAD, presencial), forma de ingresso e algum identificador para assim identificar o discente.

Essas informações auxiliam na validação dos atributos que foram extraídos dos trabalhos científicos referentes à abordagem para a previsão de desempenho de alunos de computação em disciplinas de programação, predição do rendimento dos alunos em lógica de programação com base no desempenho das disciplinas do primeiro período do curso de ciências e tecnologia utilizando técnicas de mineração de dados serão utilizados na pesquisa, utilizando comitês de classificadores para predição de rendimento escolar, avaliação do perfil de uso no ambiente moodle utilizando técnicas de mineração de dados e tratamento temporal em mineração de dados educacionais para fidelização de estudantes.

Artigos (Referência)	Objetivo	Taxa de acerto e algoritmos
Estudo da evasão de alunos de graduação utilizando Educational Data Mining (FERNANDES, 2019).	Estudo de evasão do curso de Ciência da Computação, avaliando o perfil socioeconômico através do SISU/ENEM e a situação dos alunos matriculados do primeiro ano.	KNN - 98,65%; e NN - 97,89%.
Utilizando comitês de classificadores para predição de rendimento escolar (SILVERIO, 2015).	Através de técnicas de aprendizagem de máquina, o objetivo é prever o rendimento escolar de estudantes.	KNN - 73,68421%; AD - 61,05263%; NB - 75,78947%; SVM - 76,31579%; e RNA - 75,26316%.

Mineração de dados e Evasão estudantil: Analisando o curso de nível superior do Ifes (GONÇALVES, 2020).	Identificar alunos que mostram maior risco de evasão, analisando os ingressantes do curso de Administração entre 2014 e 2018.	Algoritmos considerando a base com os atributos de frequência escolar: Stacking - 75,9%; Random Forest - 78,0%; Tree - 76,6%; Naive Bayes - 71,6%; SVM - 78,7%; Neural Network - 73,0%; Logistic Regression - 75,2%; kNN - 73,0%; CN2 rule inducer - 65,2%; SGD - 75,9%; AdaBoost - 66,0%. Algoritmos considerando a base sem os atributos de frequência escolar: Naive Bayes - 61,0%; Logistic Regression - 66,7%; CN2 rule inducer - 61,7%; Neural Network - 60,3%; AdaBoost - 64,5%; kNN - 63,8%; Random Forest - 63,1%; SVM - 65,2%; SGD - 66,0%; Stacking - 64,5%; e Tree - 53,9%.
Um estudo comparativo de classificadores na previsão da evasão de alunos em EAD (RAMOS, 2018).	Com grande quantidade de dados gerados virtualmente em ambientes de aprendizagem virtuais é utilizada a mineração de dados educacionais, aplicando cinco algoritmos e conseguindo obter acurácia acima de 90%.	RegLog - 0,856%; SVM - 0,796%; NeuralNet - 0,828%; TreeDecision - 0,788%; e KNN - 0,797%.
Uma proposta para predição de risco de evasão de estudantes em um curso técnico em informática (SARAIVA, 2019).	Utilizar de técnicas e algoritmos de aprendizagem de máquina para identificar estudantes em situação de risco.	Naive Bayes - 0,9650%; KNN - 0,9151%; Árvore de Decisão - 0,9665%; Random Forest - 0,9665%; Redes Neurais Artificiais - 0,9747%; SVM - 0,9774%.
Avaliação do Perfil de Uso no Ambiente Moodle Utilizando Técnicas de Mineração de Dados (SANTANA, 2014).	A partir da modalidade semipresencial, são extraídos dados para aplicação de técnicas de classificação para apoiar a tomada de decisão por parte de professores e gestores.	RandomForest - 65,82%; MultilayerPerceptron (MLP) - 62,02%; NaiveBayes - 73,41%; SVM - 73,41%; KNN - 64,55%; J48 - 74,68%; e RBF - 72,15%.

Tratamento temporal em mineração de dados educacionais para fidelização de estudantes (FAZOLIN, 2017).	Este trabalho apresenta uma proposta de criação de atributos temporais com o objetivo de auxiliar a previsão da evasão de alunos de Ensino Fundamental em escolas particulares, tratado como um problema de classificação.	Naive-Bayes - 81,09%; KNN - 79,25%; Árvore de Decisão - 84,92%; e SVM - 86,99%.
Uma abordagem para a previsão de desempenho de alunos de Computação em disciplinas de programação (PASCOAL, 2015).	As disciplinas de programação tendem a ter um baixo rendimento dos estudantes, com isso o projeto estuda os estudantes prováveis ao fracasso nas disciplinas iniciais de programação de cursos do Centro de Informática.	IBk - 81,9%; RandomForest (RF) - 82,9%; BayesNET (BNet) - 74,2%; e Multilayer Perceptron (MLP) - 73,1%.
Predição do rendimento dos alunos em lógica de programação com base no desempenho das disciplinas do primeiro período do curso de ciências e tecnologia utilizando técnicas de mineração de dados (BARROS, 2020).	Devido alto índice de reprovação, no trabalho é utilizado de técnicas de mineração de dados educacionais para conseguir prever o desempenho na disciplina de lógica de programação.	Árvores de decisão - 72,6%; SVM - 72,6%; Naive Bayes - 71,9%; e KNN - 76,4%.
Predição do Desempenho acadêmico de alunos da graduação Utilizando mineração de dados (MANHÃES e CRUZ, 2019).	Disponibilizar um acompanhamento sobre o desempenho dos discentes e a predição dos outros que estão em risco de abandono.	BayesNet - 81%; Naive Bayes - 82%; J48 - 81%; JRip - 83%; SVM - 79%; Multilayered Perceptrons - 79%; AdaBoost - 83%; SimpleLogistic - 83%; DecisionTable - 81%; OneR - 85%; e RandomForest - 81%.

Tabela 2: Atributos

Fonte: O autor (2020)

Está segunda tabela completa a primeira, contendo os mesmos artigos que foram estudados, mas agora apresentando os algoritmos implementados nas pesquisas e suas respectivas acurácias. Os algoritmos KNN, SVM e/ou Redes Neurais são os principais a serem citados em pesquisas relacionadas como a dissertação de Motta (2016), envolvendo um

estudo exploratório do uso de classificadores para a predição de desempenho ou na de Fazolin (2017), que trata um problema de classificação, tendo o objetivo de criar atributos temporais para ajudar a prever evasões de alunos em escolas particulares. Apenas 2 dos trabalhos estudados não implementaram o algoritmo KNN, 1 não utilizou o SVM e 3 não utilizaram Redes Neurais, os trabalhos pesquisados apresentaram uma acurácia acima de 70% para ambos os algoritmos.

5.1.2 Seleção, Pré-processamento, Transformação e Algoritmos

A base de dados disponibilizada para este trabalho contém dados relacionados ao desempenho e aproveitamento acadêmico. O resultado da revisão de literatura mostrou que as variáveis encontradas, como a procedência escolar, notas, forma de ingresso, entre outras, impactam na previsão dos algoritmos.

Como resultados parciais, foi feita apenas uma análise inicial da base para executar os algoritmos KNN e SVM. Para tanto, fez-se a seleção e o pré-processamento de uma pequena parte da base de dados original e obteve-se a base de dados da Figura 2, contendo como atributos as matérias do primeiro módulo da matriz de ensino PINF12, referente ao Projeto Pedagógico do Curso Técnico em Informática Subsequente vigente no ano de 2012, e o status, que é definido pela matéria do segundo módulo a ser referenciada para previsão, no caso a matéria Linguagem de Programação II. Os valores dos atributos são as notas nas respectivas matérias, apenas o atributo status recebeu 1, representando aprovação na matéria Linguagem de Programação II, e 2 para reprovação por nota na matéria. A base é composta por dados de 39 alunos.

ID	Montagem e Manutenção	Aplicativos para Escritórios I	Aplicativos para Escritórios II	Linguagens de Programação I	Sistemas Operacionais I	status
5358	7,1	9,9	8,4	9,8	9,1	Aprovado
7472	7,5	10	9,4	9,4	8,7	Aprovado
15084	7	7,5	7,2	8	7,1	Reprov.Nota
21504	7,3	9,5	8,8	9,6	8,7	Aprovado
21507	7	9,4	9,1	6,7	9,2	Aprovado
21510	8,1	9,2	9,4	8,3	9,1	Aprovado
21515	7,2	9,9	9,2	9,5	8,7	Aprovado
21527	7,9	9,4	8,4	6,6	7,7	Aprovado
21548	6,8	9,7	9	9,1	8,9	Aprovado
21554	8,8	9,5	9	8,1	9,5	Aprovado
21556	6,9	9,5	8,3	9,6	8,7	Aprovado
21564	8	6,6	7,1	4,9	7,8	Reprov.Nota
21576	6,6	8,7	6,6	9,3	7,2	Aprovado
21577	7,3	9,7	8,3	6,5	7,4	Aprovado
21628	7,6	9,2	9,3	7,7	8,5	Aprovado
21630	7,5	8,4	7,6	6	7,9	Aprovado
21682	9,4	9,2	9,3	8,6	9,9	Reprov.Nota
22675	8,5	9,9	9,8	6,9	8,5	Aprovado
22677	7,1	9,3	9	6	7,9	Aprovado
22681	8,5	9,9	8,3	9,6	7,6	Aprovado
22687	6,1	8,6	8,5	6,3	7,7	Aprovado
22688	8,8	9,6	9,5	7,8	8,1	Aprovado
22691	6,6	6,9	7,5	7,7	6,8	Reprov.Nota
22697	6,3	6,6	9	6,6	6,1	Aprovado
22698	6,2	8,4	8,3	6,4	7,9	Reprov.Nota
22724	8	8,9	8,9	6	8,4	Reprov.Nota
22725	8,1	8,7	9,4	8,1	6,9	Aprovado
22731	4,8	6,7	8,4	7,3	7,6	Reprov.Nota
22732	6,4	9	8,8	7	7,1	Aprovado
22741	8,6	9,2	9,3	8	7,5	Aprovado
22742	7,7	9,7	9	8	8,1	Aprovado

Figura 2: Base de dados.

Fonte: O autor (2020).

5.1.3 KNN

Com a implementação do algoritmo KNN e a base separada para treino, é possível ver na Figura 3 que o algoritmo obteve uma acurácia de 84%. E o algoritmo KNN com a base de teste da Figura 4, o resultado foi de 70% de acurácia.

```
In [22]: from sklearn.metrics import accuracy_score
accuracy_score(y_treino, predicao)
```

```
Out[22]: 0.8421052631578947
```

```
In [23]: # matriz de confusão e relatório de classificação
print("Matrix de Confusão")
print(confusion_matrix(y_treino, predicao))
print("")
print("Relatório de Classificação")
print(classification_report(y_treino, predicao))
```

Matrix de Confusão

```
[[7 0]
 [3 9]]
```

Relatório de Classificação

	precision	recall	f1-score	support
0	0.70	1.00	0.82	7
1	1.00	0.75	0.86	12
accuracy			0.84	19
macro avg	0.85	0.88	0.84	19
weighted avg	0.89	0.84	0.84	19

Figura 3: Matriz de confusão e relatório de treino do KNN.

Fonte: O autor (2020).

```
In [18]: from sklearn.metrics import accuracy_score
accuracy_score(y_teste, predicao)

Out[18]: 0.7

In [19]: from sklearn.metrics import confusion_matrix, classification_report
# matriz de confusão e relatório de classificação
print("Matrix de Confusão")
print(confusion_matrix(y_teste, predicao))
print("")
print("Relatório de Classificação")
print(classification_report(y_teste, predicao))

Matrix de Confusão
[[ 3  3]
 [ 3 11]]

Relatório de Classificação
              precision    recall  f1-score   support

     0       0.50      0.50      0.50         6
     1       0.79      0.79      0.79        14

   accuracy                0.70         20
  macro avg       0.64      0.64      0.64         20
 weighted avg       0.70      0.70      0.70         20
```

Figura 4: Matriz de confusão e relatório de teste do KNN.

Fonte: O autor (2020).

5.1.4 SVM

Implementando o algoritmo SVM, sua resposta para a acurácia foi de 94% na base de treino, como mostrado na Figura 5, e uma porcentagem de 80% na base separada para teste, demonstrada na Figura 6.

```
In [33]: from sklearn.metrics import accuracy_score
accuracy_score(y_treino, predicao2)
```

Out[33]: 0.9473684210526315

```
In [35]: from sklearn.metrics import confusion_matrix, classification_report
# matriz de confusão e relatório de classificação
print("Matrix de Confusão")
print(confusion_matrix(y_treino, predicao2))
print("")
print("Relatório de Classificação")
print(classification_report(y_treino, predicao2))
```

Matrix de Confusão

```
[[ 6  1]
 [ 0 12]]
```

Relatório de Classificação

	precision	recall	f1-score	support
0	1.00	0.86	0.92	7
1	0.92	1.00	0.96	12
accuracy			0.95	19
macro avg	0.96	0.93	0.94	19
weighted avg	0.95	0.95	0.95	19

Figura 5: Matriz de confusão e relatório de treino do SVM.

Fonte: O autor (2020).

```
In [29]: from sklearn.metrics import accuracy_score
accuracy_score(y_teste, predicao2)
```

Out[29]: 0.8

```
In [30]: from sklearn.metrics import confusion_matrix, classification_report
# matriz de confusão e relatório de classificação
print("Matrix de Confusão")
print(confusion_matrix(y_teste, predicao2))
print("")
print("Relatório de Classificação")
print(classification_report(y_teste, predicao2))
```

Matrix de Confusão

```
[[ 4  2]
 [ 2 12]]
```

Relatório de Classificação

	precision	recall	f1-score	support
0	0.67	0.67	0.67	6
1	0.86	0.86	0.86	14
accuracy			0.80	20
macro avg	0.76	0.76	0.76	20
weighted avg	0.80	0.80	0.80	20

Figura 6: Matriz de confusão e relatório de teste do SVM.

Fonte: O autor (2020).

6. CRONOGRAMA

Atividade												
	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
Projeto	X	X	X	X	X	X						
Revisão de Literatura	X	X	X	X	X	X						
Seleção, Pré-processamento e transformação					X	X	X					
Mineração de Dados - Algoritmo						X	X	X	X			
Avaliação						X	X	X	X			
Escrita de TCC e Artigos							X	X	X	X	X	X

7. ORÇAMENTO FINANCEIRO

Este trabalho utilizará equipamentos e materiais já disponíveis na instituição, não sendo necessário orçamento extra.

8. DISSEMINAÇÃO DOS RESULTADOS

Este trabalho poderá ser publicado pelo menos na Jornada Científica e Tecnológica do IFSULDEMINAS.

9. REFERÊNCIAS BIBLIOGRÁFICAS

BARROS, Renata Pitta *et al.* **Predição de Rendimento dos Alunos em Lógica de Programação com Base no Desempenho das Disciplinas de Primeiro Período do Curso de Ciência e Tecnologia Utilizando Técnicas de Mineração de Dados.** Braz. J. of Develop., Curitiba, v. 6, n. 1, p.2523-2534 jan. 2020. Disponível em: <<http://www.brjd.com.br/index.php/BRJD/article/view/6167/5484>>. Acesso em: 12/03/2020.

CARVALHO, Ricardo César. **Aplicação de mineração de dados em informações oriundas de prontuários de paciente.** Informação em Pauta, Fortaleza, v. 3, número especial, p. 161-181, nov. 2018. DOI: <<https://doi.org/10.32810/2525-3468.ip.v3iEspecial.2018.39723.161-181>>.

CORADINE, L.C., et al. **Mineração de Dados: Uma Introdução**. Learning and Nonlinear Models (L&NLM) – Journal of the Brazil Neural Networks Society, Vol. 9, 2011, p. 168-184.

FACELI, K., Lorena, A. C., Gama, J., and de Carvalho, A. C. P. L. F. (2011). **Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina**. LTC, Rio de Janeiro.

FACELLI, Katti.; LORENA, Ana Carolina; GAMA, João; CARVALHO, André C.P.L.F. **Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina**. Rio de Janeiro: LTC, 2011.

FAZOLIN, Kleyton. **TRATAMENTO TEMPORAL EM MINERAÇÃO DE DADOS EDUCACIONAIS PARA FIDELIZAÇÃO DE ESTUDANTES**. 2017. 74 f. Tese (Doutorado) - Curso de Computação Aplicada, Universidade Tecnológica Federal do Paraná, Curitiba, 2017.

FERNANDES, Karina Casola. **Estudo da evasão de alunos de graduação utilizando Educational Data Mining**. 2019. 91 f. TCC (Graduação) - Curso de Ciência da Computação, Universidade Federal do Pampa, Alegrete, 2019.

FURLAN, Matheus Batista. **ALGORITMOS E TÉCNICAS PARA MINERAÇÃO DE DADOS**. 2018, 51f: Projeto de pesquisa apresentado ao curso de do Instituto Municipal de Ensino Superior de Assis, IMESA e a Fundação Educacional do Município de Assis – FEMA, Local, v. 2018, Número, p. XX-YY, dez./2005. Disponível em: <<https://cepein.femanet.com.br/BDigital/arqTccs/1511420203.pdf>>. Acesso em: 12/03/2020.

GOMES, Georgia Regina Rodrigues *et al.* **APLICAÇÃO DO PROCESSO DE DESCOBERTA DE CONHECIMENTO EM BASES DE DADOS NUM PROCESSO SELETIVO DE EDUCAÇÃO A DISTÂNCIA**. Cobenge, Juiz de Fora, v. 42, p. Set. 2014.

GOMES, Simone Aparecida. **PROGRAMA DE PÓS-GRADUAÇÃO EM GESTÃO E ORGANIZAÇÃO DE SISTEMAS PÚBLICOS**. 2018. 124 f. Dissertação (Mestrado) - Curso de Gestão e Organização de Sistemas Públicos, Universidade Federal de São Carlos, São Carlos, 2018.

GONÇALVES, Oldair Luiz; BELTRAME, Walber Antonio Ramos. **MINERAÇÃO DE DADOS E EVASÃO ESTUDANTIL: ANALISANDO O CURSO DE NÍVEL SUPERIOR DO IFES EM GUARAPARI**. In: Anais do XII CASI - Congresso de Administração, Sociedade e Inovação. Anais...Palhoça(SC) FATENP - Unigranrio, 2019. Disponível em: <<https://www.even3.com.br/anais/12casi/200666-MINERACAO-DE-DADOS-E-EVASAO-E>>

STUDANTIL--ANALISANDO-O-CURSO-DE-NIVEL-SUPERIOR-DO-IFES-EM-GUARA PARI>. Acesso em: 14/06/2020 15:50

KAMPPF, Adriana Justin Cerveira; REATEGUI, Eliseo Berni; LIMA, José Valdeni de. **Mineração de dados educacionais para a construção de alertas em ambientes virtuais de aprendizagem como apoio à prática docente**. Novas Tecnologias na Educação: subtítulo da revista, Porto Alegre - RS, v. 6, n. 2, p. XX-YY, dez./2008. Disponível em: <<https://seer.ufrgs.br/renote/article/view/14394/8291> >. Acesso em: 12/03/2020

MACHADO, Roger Douglas *et al.* **ESTUDO BIBLIOMÉTRICO EM MINERAÇÃO DE DADOS E EVASÃO ESCOLAR**. Congresso Nacional de Excelência em Gestão: subtítulo da revista, Rio de Janeiro, RJ, Volume, n. 11, p. XX-YY, ago./2015. Disponível em: <http://www.inovarse.org/sites/default/files/T_15_210_1.pdf >. Acesso em: 12/03/2020

MANHÃES, Laci Mary Barbosa. **Predição do Desempenho Acadêmico de Alunos da Graduação Utilizando Mineração de Dados**. Rio de Janeiro, 2015. Disponível em: <<https://www.cos.ufrj.br/uploadfile/1426690008.pdf> >. Acesso em: 12/03/2020.

MANHÃES, Laci Mary B.; CRUZ, Sérgio Manuel Serra da. **Predição do Desempenho Acadêmico de Alunos da Graduação Utilizando Mineração de Dados**. In: SIMPÓSIO DE PESQUISA OPERACIONAL E LOGÍSTICA DA MARINHA, 19., 2019, Rio de Janeiro, RJ. Anais [...]. Rio de Janeiro: Centro de Análises de Sistemas Navais, 2019.

MORAIS, César Batista de *et al.* **ANUÁRIO EDUCACIONAL ESTATÍSTICO**. Pouso Alegre: Secretaria de Educação Profissional e Tecnológica Instituto Federal de Educação, Ciência e Tecnologia do Sul de Minas Gerais, 2019. 83 p.

MOTTA, Porthos Ribeiro de Albuquerque. **Estudo Exploratório de Uso de Classificadores para a Predição de Desempenho e Abandono em Universidades**. Goiânia, 2016. Disponível em: <<https://pdfs.semanticscholar.org/001f/1f5b8a00dbdcb9847deb5b16faf3949d1957.pdf> >. Acesso em: 12/03/2020.

PASCOAL, Túlio Albuquerque; BRITO, Daniel Miranda de; RÊGO, Thaís Gaudencio do. **Uma abordagem para a previsão de desempenho de alunos de Computação em disciplinas de programação**. Conferência Internacional Sobre Informática na Educação: subtítulo da revista, João Pessoa – PB, v. 1, n. 20, p. 454-458, dez./2005. Disponível em: <<http://www.tise.cl/volumen11/TISE2015/454-458.pdf> >. Acesso em: 12/03/2020.

PAZ, Fábio Josende; CAZELLA, Sílvio César. **Identificando o perfil de evasão de alunos de graduação através da Mineração de dados Educacionais: um estudo de caso de uma**

Universidade Comunitária. Congresso Brasileiro de Informática na Educação: subtítulo da revista, Local, Volume, n. 6, p. 624-633, nov./2017. Disponível em: <<https://pdfs.semanticscholar.org/ffae/586cfd9ce731f09887abf799a96fd8dd450c.pdf>>. Acesso em: 12/03/2020.

PEDREGOSA, Fabian & VAROQUAUX, Gael & GRAMFORET, Alexandre & MICHEL, Vincent & THIRION, Bertrand & GRISEL, Olivier & BLONDEL, Mathieu & PRETTENHOFER, Peter & WEISS, Ron & DUBOURG, Vincent & VANDERPLAS, Jake & Passos, Alexandre & COURNAPEAU, David & BRUCHER, Matthieu & PERROT, Matthieu & DUCHESNAY, Edouard & LOUPPE, Gilles. (2012). **Scikit-learn: Machine Learning in Python**. Journal of Machine Learning Research. 12.

PPC (Projeto Pedagógico do Curso). **Projeto Pedagógico do Curso Técnico Subsequente em Informática**. Muzambinho: Secretaria de Educação Profissional e Tecnológica Instituto Federal de Educação, Ciência e Tecnologia do Sul de Minas Gerais, 2019. 63 p.

PPC (Projeto Pedagógico do Curso). **PROJETO PEDAGÓGICO DO CURSO TÉCNICO EM INFORMÁTICA - SUBSEQUENTE**. Muzambinho: Secretaria de Educação Profissional e Tecnológica Instituto Federal de Educação, Ciência e Tecnologia do Sul de Minas Gerais, 2016. 88 p.

RAMOS, Jorge Luis Cavalcanti; SILVA, João; PRADO, Leonardo; GOMES, Alex; RODRIGUES, Rodrigo. **Um estudo comparativo de classificadores na previsão da evasão de alunos em EAD**. Anais do Xxix Simpósio Brasileiro de Informática na Educação (sbie 2018), [s.l.], v. 7, p. 1463-1472, 28 out. 2018. Brazilian Computer Society (Sociedade Brasileira de Computação - SBC). <http://dx.doi.org/10.5753/cbie.sbie.2018.1463>.

RIGO, Sandro J. *et al.* **Aplicações de Mineração de Dados Educacionais e Learning Analytics com foco na evasão escolar: oportunidades e desafios**. Revista Brasileira de Informática na Educação: subtítulo da revista, Local, v. 22, n. 1, p. 133-146, mar./2014. DOI: <<http://dx.doi.org/10.5753/rbie.2014.22.01.132>>. Acesso em: 12/03/2020.

SARAIWA, Daniel; PEREIRA, Silas; GALLINDO, Erica; BRAGA, Reinaldo; OLIVEIRA, Carina. **Uma proposta para predição de risco de evasão de estudantes em um curso técnico em informática**. In: WORKSHOP SOBRE EDUCAÇÃO EM COMPUTAÇÃO (WEI), 27. , 2019, Belém. Anais do XXVII Workshop sobre Educação em Computação. Porto Alegre: Sociedade Brasileira de Computação, July 2019 . p. 319-333. ISSN 2595-6175. DOI: <<https://doi.org/10.5753/wei.2019.6639>>.

SANTANA, Leandro C.; MACIEL, Alexandre M. A.; RODRIGUES, Rodrigo L.. **Avaliação do Perfil de Uso no Ambiente Moodle Utilizando Técnicas de Mineração de Dados**.

Anais do Xxv Simpósio Brasileiro de Informática na Educação (sbie 2014), [s.l.], v. 25, p. 269-277, 3 nov. 2014. Sociedade Brasileira de Computação - SBC.
<<http://dx.doi.org/10.5753/cbie.sbie.2014.269>>.

SANTOS, Tatiane Gomes dos. **ANÁLISE DE OPINIÕES UTILIZANDO TÉCNICAS DE MINERAÇÃO DE DADOS EM REDES SOCIAIS.**: estudo de caso: twitter.. 2017. 48 f. Trabalho de Conclusão de Curso (Graduação) - Curso de Engenharia de Computação, Centro Universitário de Anápolis– Unievangélica, Anápolis, 2017.

SILVERIO, Priscilla Suene de Santana Nogueira. **Utilizando comitês de classificadores para predição de rendimento escolar.** 2015. 165 f. Dissertação (Mestrado) - Curso de Sistemas e Computação do Departamento de Informática e Matemática Aplicada, Universidade Federal do Rio Grande do Norte, Natal - Rn, 2015..

VANDERPLAS, Jake. **Python data science handbook.** [s. L.]: O'reilly, 2016. 548 p.

Muzambinho, 14 de Junho de 2020.

ANEXO A – Requerimento de dados



Ministério da Educação
Secretaria de Educação Profissional e Tecnológica
Instituto Federal de Educação, Ciência e Tecnologia do Sul de Minas Gerais - IFSULDEMINAS - Campus
Muzambinho Estrada de Muzambinho, Km 35, Morro Preto, Muzambinho / MG, CEP 37.890-000 - Fone: (35)
3571-5051

REQUERIMENTO 95/2020 - CGE-MUZ/DE-MUZ/MUZ/IFSULDEMINAS

2 de junho de 2020

Venho por meio deste pedir autorização de uso de dados institucionais acadêmicos do IFSULDEMINAS para fins de pesquisa no trabalho de conclusão de curso intitulado Aplicação de Ciência de Dados em Bases de Informações Escolares, do aluno Lucas José Serra Matthes do curso de Ciência da Computação. O trabalho tem por objetivo prever o aproveitamento (aprovado/reprovado) discente nos cursos Técnicos em Informática Subsequente do IFSULDEMINAS, modalidades presencial e EAD, por meio do uso de algoritmos.

Os dados pessoais de alunos/professores não são necessários, devendo ser omitidos. Precisaremos de informações como a modalidade de ensino, notas nas disciplinas dos módulos I e II, ano de entrada no curso, para cada disciplina se o aluno ficou de exame/recuperação, formação do professor, dentre outros.

Documento assinado eletronicamente por:

- Aline Marques Del Valle, PROFESSOR ENS BASICO TECN TECNOLOGICO, em 02/06/2020 16:37:07.
- Aracele Garcia de Oliveira Fassbinder, DIRETOR - MUZ- DDE-MUZ, em 02/06/2020 14:56:36.

Este documento foi emitido pelo SUAP em 01/06/2020. Para comprovar sua autenticidade, faça a leitura do QRCode ao lado ou acesse <https://suap.ifsuldeminas.edu.br/autenticar-documento/> e forneça os dados abaixo:

Código Verificador: 66312

Código de Autenticação: d9907550a2



Documento eletrônico gerado pelo SUAP (<https://suap.ifsuldeminas.edu.br>)
Instituto Federal de Educação, Ciência e Tecnologia do Sul de Minas Gerais